

Interpretação de Imagens

Luiz Eduardo da Silva

Processamento de Imagens

Ciência da Computação

UNIFAL-MG

Agenda

- 1 Reconhecimento e interpretação
 - Padrões
 - Assinatura
 - Descrição estrutural
 - Casamento de Padrões
 - Redes Neurais
 - Redes Neurais Convolucionais - CNN

Agenda

- 1 Reconhecimento e interpretação
 - Padrões
 - Assinatura
 - Descrição estrutural
 - Casamento de Padrões
 - Redes Neurais
 - Redes Neurais Convolucionais - CNN

Motivação

- Algumas técnicas para reconhecimento de objetos ou padrões.
Duas áreas principais:
 - Usa decisão teórica: aborda padrões com descritores quantitativos, como comprimento, área e textura).
 - Usa decisão estrutural: aborda padrões com descritores qualitativos.
- Um conceito importante quando se fala de reconhecimento/interpretação de imagens diz respeito à "aprendizagem".

Padrões e classes de padrões

- Um *padrão* é um arranjo de *descritores* (também chamados de *características*).
- Uma classe de padrões é um família de padrões que compartilham algumas propriedades em comum. As classes são identificadas com $w_1, w_2, \dots, w_W$, onde W é o número de classes.
- O reconhecimento automático de padrões envolve técnicas que associa padrões as suas respectivas classes, com a menor intervenção humana possível.
- Usa-se normalmente arranjos de padrões na forma de **vetores** (para descrições quantitativas), **strings** e **árvores** (para descrições estruturais).


Vetores de características (feature vector ou pattern vector)

- São representados por letras minúsculas em negrito, como **x**, **y** e **z**, e tem a forma:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$


na qual cada componente x_i , representa o *i-ésimo* descritor e n é o número total de descritores associado ao padrão.

Exemplo



- Classificação das flores íris.
- Duas características $x = [x_1, x_2]^T$, sendo x_1 e x_2 , o comprimento e a largura da pétala.
- Três classes de padrões: w_1 , w_2 e w_3 , correspondem às variedades *setosa*, *virginica* e *versicolor*.
- As flores são pontos num espaço bidimensional.

Assinatura



Descrição estrutural




Figura: Estrutura na forma de escada. Representação por strings geram padrões de objetos

Descrição estrutural



Figura: Imagem de satélite de Washington, D.C.

Descrição estrutural





Figura: Descrição na forma de árvore da imagem de satélite

Descrição estrutural



Casamento




Figura: Casamento de padrão

Correlação





Figura: a) imagem de um furacão, b) padrão do olho do furacão, c) Coeficiente de correlação e d) Localização do melhor casamento de padrão

Redes Neurais



Redes Neurais com múltiplas camadas





FIGURE 12.16 Multilayer feedforward neural network model. The blowup shows the basic structure of each neuron element throughout the network. The offset, θ_j , is treated as just another weight.


CNN

- Redes Neurais Convolucionais (CNNs, em inglês), tem sido usadas para reconhecimento de imagens, processamento de voz e linguagem natural e surgiu do estudo do córtex visual do cérebro.
- Estudos do córtex visual mostraram que muitos dos seus neurônios reagem a estímulos visuais localizadas em uma região limitada do campo visual



CNN


- A camada de construção mais importante de uma CNN é a *camada convolucional*.



CNN

- O número de neurônios necessários para uma RN *feedforward*, para o processamento de imagens, pode ser proibitivo. Exemplo: Uma imagem 1000x1000 são necessários 10^6 neurônios, se considerarmos um neurônio para cada pixel da imagem.
- De forma bem simplificada, podemos dizer que uma CNN consegue extrair padrões de uma imagem e diminuir sua dimensão, sem perder suas características.

Redução de dimensão




Exemplo de CNN: A imagem de entrada ocupa $224 \times 224 \times 3 = 100.352$ neurônios. Depois das camadas da CNN, a dimensão é reduzida para $1 \times 1 \times 1000 = 1000$ neurônios.

Algumas definições

- Podemos interpretar uma imagem colorida, como a combinação de três matrizes. Cada matriz, representa a intensidade do vermelho, verde e azul em cada pixel.
- Linhas verticais e horizontais são combinadas para formar a imagem. Filtros com a operação de convolução podem ser usados para detectar essas arestas.
- *Stride* - é o parâmetro que define o passo da máscara de convolução.
- *Padding* - é o parâmetro que define a janela de zeros que contorna a matriz imagem, para manter a mesma dimensão da matriz de entrada e saída da convolução.


Camadas da CNN

Camadas da CNN



Camadas da CNN

- Camada *Input* - É a camada que contém a imagem.
- Camada *Convo* - também chamada de camada de extração de características. A imagem é conectada a Convo layer para executar a operação de convolução. Convo layer contém ativação ReLu que torna todos os valores negativos em zero.
- Camada *Pooling* - É a camada usada para reduzir a dimensão da imagem de entrada depois da convolução.




Função de ativação

Activation Functions


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




tanh

$$\tanh(x)$$




ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$




Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Pooling Layer

- Tem dois hiperparâmetros para camada *Pooling* - *Filter*(F) e *Stride*(S). Se a imagem de entrada tem dimensão: $w_1 \times h_1 \times d_1$, Então a imagem de saída da camada pooling terá:

$$w_2 = (w_1 - F)/S + 1$$

$$h_2 = (h_1 - F)/S + 1$$


$$d_2 = d_1$$

Camadas da CNN


- Camada *Fully Connected (FC)* - é a camada da rede neural com pesos, inclinação e neurônios. Conecta uma camada de neurônios a outra camada de neurônios.
- Camada *Logistic/Softmax* - é a camada no final da camada FC. Logistic é usada para classificação binária e softmax para multiclassificação.
- Camada *Output* - contém o rótulo da camada de classificação.

Camadas *Dropout*

A camada *Dropout*, não representada no fluxo original, é outra camada típica que pode ser incluída na arquitetura de uma rede CNN. A camada *Dropout* é uma máscara para anular a contribuição de alguns neurônios, deixando outros sem modificação.



Without Dropout



With Dropout

Arquiteturas CNN

Arquiteturas típicas de CNN empilham camadas convolucionais (seguida por camada ReLU), depois camadas de pooling, depois outras camadas convolucionais e assim por diante.

Foram desenvolvidas várias arquiteturas. As mais bem sucedidas são:

- LeNet-5
- AlexNet
- GoogleNet
- ResNet

Arquitetura LeNet-5

Table 13-1. LeNet-5 architecture

Layer	Type	Maps	Size	Kernel size	Stride	Activation
Out	Fully Connected	–	10	–	–	RBF
F6	Fully Connected	–	84	–	–	tanh
C5	Convolution	120	1×1	5×5	1	tanh
S4	Avg Pooling	16	5×5	2×2	2	tanh
C3	Convolution	16	10×10	5×5	1	tanh
S2	Avg Pooling	6	14×14	2×2	2	tanh
C1	Convolution	6	28×28	5×5	1	tanh
In	Input	1	32×32	–	–	–

Arquitetura AlexNet

Table 13-2. AlexNet architecture

Layer	Type	Maps	Size	Kernel size	Stride	Padding	Activation
Out	Fully Connected	–	1,000	–	–	–	Softmax
F9	Fully Connected	–	4,096	–	–	–	ReLU
F8	Fully Connected	–	4,096	–	–	–	ReLU
C7	Convolution	256	13×13	3×3	1	SAME	ReLU
C6	Convolution	384	13×13	3×3	1	SAME	ReLU
C5	Convolution	384	13×13	3×3	1	SAME	ReLU
S4	Max Pooling	256	13×13	3×3	2	VALID	–
C3	Convolution	256	27×27	5×5	1	SAME	ReLU
S2	Max Pooling	96	27×27	3×3	2	VALID	–
C1	Convolution	96	55×55	11×11	4	SAME	ReLU
In	Input	3 (RGB)	224×224	–	–	–	–