Classificação de Tumores Cerebrais em Imagens de Ressonância Magnética Utilizando Transferência de Aprendizado

Uma análise comparativa de desempenho, eficiência computacional e explicabilidade

Pedro Brassi Luccas

Universidade Federal de Alfenas – UNIFAL
Ciência da Computação

Orientador: Professor Doutor Luiz Eduardo da Silva

2026

Sumário

1. Resumo
2. Problemática
3. Justificativa
4. Objetivos
5. Metodologia
6. Cronograma
7. Bibliografia

Resumo da proposta

- Classificação de tumores cerebrais em RM: **glioma, meningioma, tumor hipofisário, ausência de tumor**
- Transferência de aprendizado com **ResNet50, EfficientNet-B0 e MobileNetV3**
- **Auditoria e deduplicação** da base antes do treinamento (SHA-256 + pHash/dHash)
- Avaliação por acurácia, Macro F1-Score, AUC-ROC *one-vs-rest* e matriz de confusão, além de parâmetros, tamanho e tempo de inferência
- Explicabilidade exploratória via **Grad-CAM**

→ Objetivo: efeito da deduplicação sobre o desempenho e melhor equilíbrio entre arquiteturas

Finalidade acadêmica – não pretende validar ferramenta de diagnóstico clínico.

Contexto e delimitação do tema

- RM detalha tecidos cerebrais, mas a análise exige conhecimento especializado e grande volume de imagens
- CNNs aprendem características visuais automaticamente, porém exigem grandes bases de treino
- Transferência de aprendizado reduz essa demanda, adaptando modelos pré-treinados (ImageNet)

Delimitação

Classificação multiclasse 2D em 4 categorias, comparando ResNet50, EfficientNet-B0 e MobileNetV3, avaliando desempenho, custo computacional, efeito da deduplicação e interpretabilidade (Grad-CAM).

O problema: vazamento de dados

Risco metodológico

Duplicatas, versões modificadas da mesma imagem ou cortes do mesmo paciente distribuídos entre treino e teste podem causar **vazamento de dados** – a acurácia isolada não descreve adequadamente um classificador médico multiclasse.

Problema de pesquisa

Como a deduplicação da base e a escolha da arquitetura de transferência de aprendizado influenciam o desempenho, a eficiência computacional e a interpretabilidade de modelos para classificação de tumores cerebrais em RM?

Questão principal e questões secundárias

Questão principal: qual arquitetura (ResNet50, EfficientNet-B0, MobileNetV3) apresenta o melhor equilíbrio entre desempenho, eficiência computacional e interpretabilidade? **Questões secundárias:**

- A remoção de duplicatas/similares modifica significativamente o desempenho?
- Qual arquitetura apresenta o melhor Macro F1-Score?
- Quais classes apresentam maior frequência de confusão?
- Modelos compactos mantêm desempenho competitivo frente a modelos maiores?
- As regiões do Grad-CAM são visualmente coerentes com as áreas relevantes?

Hipóteses

Hipótese principal: a transferência de aprendizado permite desempenho satisfatório mesmo com base de tamanho limitado.

- **H1** Remoção de duplicatas/similares reduz métricas artificialmente elevadas
- **H2** Trade-off desempenho $\times$ custo: EfficientNet-B0 com melhor equilíbrio geral; ResNet50 competitiva, maior custo; MobileNetV3 compacta e próxima às demais
- **H3** Aumento de dados (apenas no treino) reduz o sobreajuste
- **H4** Grad-CAM revela decisões baseadas em regiões irrelevantes ou artefatos

Lacuna de pesquisa

- Base *Brain Tumor MRI Dataset* já relatou 98,73%–99,96% de acurácia em estudos recentes (DISCI; GURCAN; SOYLU, 2025; RASA et al., 2024)
- **Yagis et al. (2021)**: divisão em nível de fatia 2D pode inflar artificialmente a acurácia entre **29 e 55 pontos percentuais**, a depender da base neurológica (OASIS, ADNI, PPMI, base local de Parkinson)
- **Fateh et al. (2026)**: ao reconstruir a mesma base, apontam remoção de duplicatas/quase-duplicatas como etapa necessária contra vazamento

Lacuna

Não há, até o momento, trabalhos que apliquem essa auditoria diretamente sobre a base original combinada às três arquiteturas propostas.

Justificativa

Teórica Metodologia precisa considerar qualidade dos dados e risco de vazamento, não só acurácia final. Auditoria de duplicatas é o principal diferencial metodológico.

Social Diagnóstico precoce melhora sobrevida. Contribui ao apoio computacional ao diagnóstico por imagem, com potencial benefício indireto futuro.

Tecnológica Bases públicas viabilizam estudo sem coleta clínica direta; produz pipeline reprodutível (auditoria, treino, explicabilidade).

Objetivo geral

Desenvolver e avaliar modelos de classificação de tumores cerebrais em RM utilizando transferência de aprendizado, comparando desempenho preditivo, eficiência computacional, influência da deduplicação e explicabilidade.

Objetivos específicos

- Selecionar e documentar uma base pública de ressonâncias magnéticas
- Analisar distribuição, origem, licença, formatos e qualidade das imagens
- Detectar duplicatas exatas (hash criptográfico) e similares (hash perceptual)
- Definir divisões de treino/validação/teste sem vazamento conhecido
- Implementar uma CNN simples como *baseline*
- Aplicar ResNet50, EfficientNet-B0 e MobileNetV3 com transferência de aprendizado
- Comparar métricas preditivas e computacionais, com e sem deduplicação
- Analisar erros e matrizes de confusão por classe
- Aplicar Grad-CAM e discutir limitações, vieses e generalização

Natureza da pesquisa e base de dados

Natureza: pesquisa aplicada, quantitativa, experimental e exploratória. **Base de dados:** *Brain Tumor MRI Dataset* (Nickparvar, 2021, Kaggle) – 4 classes (glioma, meningioma, tumor hipofisário, ausência de tumor).

- Registro de quantidade por classe, formato, resolução, licença e fontes primárias
- Kaggle tratado como plataforma de redistribuição (citação da origem original)
- Inclusão: arquivos legíveis, rótulos válidos, licença compatível
- Exclusão/análise à parte: corrompidos, rótulos ausentes/ambíguos, duplicatas confirmadas, origem inadequada

Auditoria, deduplicação e divisão dos dados

- Auditoria **antes** da divisão dos dados
- **SHA-256**: identifica arquivos exatamente iguais
- **pHash/dHash** (distância de Hamming): sinaliza similaridade visual
- Pares registrados, agrupados e inspecionados por amostragem – sem exclusão automática (podem ser cortes distintos de um mesmo exame)

Divisão dos dados

Base não disponibiliza identificadores de paciente $\Rightarrow$ divisão **estratificada por classe**: 70% treino / 15% validação / 15% teste. Duplicatas de um mesmo grupo ficam em uma única partição; teste isolado até a definição final.

Pré-processamento, modelos e treinamento

- Conversão de canais, redimensionamento com preservação de proporção, normalização específica do modelo
- Aumento de dados (treino apenas): rotações, translações, zoom, ajustes leves de brilho/contraste
- CNN simples como *baseline*
- Redes pré-treinadas: extratores congelados → nova cabeça de classificação → **fine-tuning parcial** com taxa de aprendizado menor
- Condições equivalentes entre experimentos: divisão, transformações, épocas, *early stopping*, seleção de checkpoint

Desequilíbrio de classes

Se a auditoria revelar desequilíbrio relevante: *class weighting* ou reamostragem.

Plano experimental

Exp.	Modelo	Base
E1	CNN *baseline*	sem deduplicação
E2	EfficientNet-B0 pré-treinada*	sem deduplicação
E3	CNN *baseline*	deduplicada
E4	ResNet50	deduplicada
E5	EfficientNet-B0	deduplicada
E6	MobileNetV3	deduplicada
E7	Grad-CAM + análise de erros	melhor modelo

*Representa as arquiteturas em E2 por H2 indicar seu melhor equilíbrio geral.

- **H1 (dedup.)**: medida de forma completa em E1 vs. E3; representativa em E2 vs. E5
- Extensão a ResNet50/MobileNetV3: conforme cronograma

Métricas e determinação do "melhor equilíbrio"

Métricas preditivas: acurácia, precisão, sensibilidade, especificidade, F1 por classe, Macro F1, Macro AUC, AUC-ROC *one-vs-rest*, matriz de confusão **Métricas computacionais:** parâmetros totais/treináveis, tamanho (MB), tempo de inferência

Melhor equilíbrio

Determinado de forma **qualitativa e discursiva**, comparando métricas e resultados do Grad-CAM – sem fórmula de ponderação formal única.

Explicabilidade e tecnologias

Explicabilidade: Grad-CAM (Selvaraju et al., 2017) em amostra de acertos de alta confiança e erros mais frequentes da matriz de confusão.

Categoria	**Ferramentas possíveis**
Linguagem e IA	Python; PyTorch ou TensorFlow/Keras; scikit-learn
Imagem e dados	OpenCV; Pillow; ImageHash; NumPy; Pandas
Visualização	Matplotlib; Seaborn
Ambiente	Jupyter; Google Colab; Kaggle
Versionamento	Git e GitHub

Extensões (se o cronograma permitir): testes estatísticos formais, FLOPs/MACs, validação externa.

Cronograma da pesquisa

Indicativo para dez meses – ajustado em conjunto com o orientador.

Atividade	1	2	3	4	5	6	7	8	9	10
Tema e problema	C									
Revisão bibliográfica		P	P							
Base e documentação		C								
Auditoria/deduplicação										
Pré-processamento										
Baseline										
Treinamento (E1–E6)										
Ajustes										
Avaliação										
Grad-CAM (E7)										
Extensões (se houver tempo)										
Redação		P	P							
Revisão/apresentação										

C: concluído. P: parcialmente realizado.

Bibliografia principal I

- DISCI, R.; GURCAN, F.; SOYLU, A. Advanced brain tumor classification in MR images using transfer learning and pre-trained deep CNN models. *Cancers*, v. 17, n. 1, p. 121, 2025.
- FATEH, A. et al. BRISC: annotated dataset for brain tumor segmentation and classification. *Scientific Data*, 2026.
- HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: *CVPR*, 2016, Las Vegas. p. 770–778.
- HOWARD, A. et al. Searching for MobileNetV3. In: *ICCV*, 2019, Seoul. p. 1314–1324.
- NICKPARVAR, M. Brain Tumor MRI Dataset. *Kaggle*, 2021.
- SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: *ICCV*, 2017, Venice. p. 618–626.
- TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: *ICML*, 36., 2019, Long Beach. p. 6105–6114.
- YAGIS, E. et al. Effect of data leakage in brain MRI classification using 2D convolutional neural networks. *Scientific Reports*, v. 11, n. 22544, 2021.

Bibliografia principal II

Bibliografia complementar

- RASA, S. M. et al. Brain tumor classification using fine-tuned transfer learning models on MRI images. *Digital Health*, v. 10, 2024.

Tese

A transferência de aprendizado permite classificar tumores cerebrais em RM com desempenho satisfatório mesmo em uma base de tamanho limitado – mas apenas uma auditoria rigorosa de duplicatas revela se esse desempenho é real ou artificialmente inflado por vazamento de dados entre treino e teste.

Obrigado!

Perguntas?