UNIVERSIDADE FEDERAL DE ALFENAS · UNIFAL-MG

Classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado

Uma análise comparativa de desempenho, eficiência computacional e explicabilidade

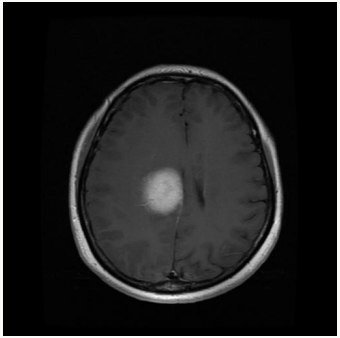
Pedro Brassi Luccas
Orientador: Prof. Dr. Luiz Eduardo da Silva

TCC I · Ciência da Computação · 2026



Exemplos da base Brain Tumor MRI Dataset (Nickparvar, 2021). Rótulos da base.

Contextualização



Exemplo da classe “meningioma”

1. A ressonância mostra o cérebro em detalhe.
2. A interpretação exige especialistas.
3. A IA pode ajudar a reconhecer padrões.

Como a computação pode contribuir?

Imagem: Nickparvar (2021). Rótulo da base, sem validação clínica independente.

Resultados na literatura

Disci et al. (2025)

98,73%

Acurácia ponderada

No teste: 95,27%

Rasa et al. (2024)

99,96%

Com tumor × sem tumor

Validação cruzada

Prayogo et al. (2025)

98,75%

Quatro classes

Três redes combinadas

Mas podemos confiar apenas nesses números?

Estudos com dados e métodos diferentes: valores não comparáveis entre si.

Vazamento de dados: por que isso importa?

- **Yagis et al. (2021):** até 55 pontos percentuais de aumento artificial por vazamento entre imagens do mesmo paciente. Estudo com Alzheimer e Parkinson.
- **Fateh et al. (2026):** remoção de duplicatas antes da divisão entre treino e teste.



Esquema conceitual com repetição intencional: o teste deixa de ser independente.

LACUNA INVESTIGADA

Necessidade de avaliar conjuntamente o efeito das duplicatas e o equilíbrio entre desempenho e custo computacional dos modelos.

Justificativa

Por que avaliar a confiabilidade dos resultados?

TEÓRICA

Investigar como a qualidade dos dados influencia a avaliação dos modelos.

SOCIAL

Contribuir para pesquisas mais confiáveis em apoio ao diagnóstico por imagem.

TECNOLÓGICA

Desenvolver um processo reprodutível de preparação dos dados, treinamento e avaliação.

Foco: a confiabilidade do método computacional, não uma ferramenta de uso clínico.

Objetivos da pesquisa

OBJETIVO GERAL

Desenvolver e avaliar modelos de classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado, considerando desempenho, eficiência computacional, deduplicação e explicabilidade.

01
Auditar
a base de imagens

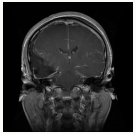
02
Treinar
quatro modelos

03
Comparar
desempenho e custo

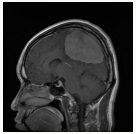
04
Investigar
erros e decisões

Base de dados e preparação

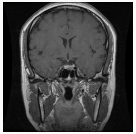
Brain Tumor MRI Dataset (Nickparvar, 2021), disponível no Kaggle: quatro categorias



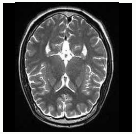
Glioma
células da glia



Meningioma
meninges



Tumor hipofisário
hipófise



Ausência de tumor
comparação



- Aumento de dados somente no treinamento.

Rótulos da base. Sem identificadores de paciente.

Modelos e plano experimental

REDES PRÉ-TREINADAS

ResNet50
Conexões que facilitam o aprendizado.

EfficientNet-B0
Equilíbrio entre desempenho e eficiência.

MobileNetV3
Arquitetura compacta e eficiente.

Transferência de aprendizado
Adaptação de modelos já treinados para classificar imagens de ressonância magnética.

EXPERIMENTOS

	Sem deduplicação	Com deduplicação
CNN simples	E1	E3
EfficientNet-B0	E2	E5
ResNet50	—	E4
MobileNetV3	—	E6

Efeito da deduplicação
Comparação das arquiteturas
E7: Grad-CAM no melhor modelo

He et al. (2016); Tan e Le (2019); Howard et al. (2019).

Avaliação dos modelos

Desempenho

Acurácia

Macro F1

Combina precisão e sensibilidade, com igual peso para cada classe.

Matriz de confusão

Eficiência

Parâmetros

Tamanho (MB)

Tempo de inferência

Explicabilidade

Grad-CAM

regiões que influenciam a decisão

Avaliar quanto o modelo acerta, quanto custa e quais regiões influenciam suas decisões.

Selvaraju et al. (2017). Grad-CAM não é segmentação nem validação clínica.

Hipóteses e limitações

Hipóteses

Deduplicação
Remover imagens repetidas altera as métricas de classificação.

Arquiteturas
Os modelos apresentam diferenças de desempenho e custo computacional.

Análise exploratória

Grad-CAM
Investigar erros e regiões que influenciam as classificações.

Limitações

Separação por paciente
Sem identificadores, não é possível garantir pacientes diferentes em treino e teste.

Generalização
Os resultados podem variar em outras bases.

Aplicação clínica
O estudo não valida o uso dos modelos no diagnóstico médico.

Cronograma da pesquisa

Seis meses, a ajustar com o orientador

Atividade	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6
Tema e problema	C					
Revisão bibliográfica	P					
Base e documentação	C					
Auditoria/deduplicação						
Pré-processamento						
Baseline						
Treinamento (E1–E6)						
Ajustes						
Avaliação						
Grad-CAM (E7)						
Extensões (se houver tempo)						
Redação	P					
Revisão/apresentação						

C concluído P parcialmente realizado vazio: período a definir

Fonte: pré-projeto, p. 8

Mais do que obter uma alta acurácia, é necessário avaliar a confiabilidade dos resultados.

- Qualidade dos dados
- Avaliação comparativa
- Explicabilidade

Obrigado! Perguntas?

Referências bibliográficas

Classificação e qualidade dos dados

DISCI, R.; GURCAN, F.; SOYLU, A. (2025)
Advanced brain tumor classification in MR images using transfer learning and pre-trained deep CNN models. *Cancers*, 17, 121.
DOI: 10.3390/cancers17010121

RASA, S. M. et al. (2024)
Brain tumor classification using fine-tuned transfer learning models on magnetic resonance imaging (MRI) images. *Digital Health*, 10.
DOI: 10.1177/20552076241286140

PRAYOGO, R. D.; HAMID, N.; NAMBO, H. (2025)
Hybrid CNN-Based Transfer Learning Enhances Brain Tumor Classification on MRI Images. *IEEE Access*, 13, 116654–116668.
DOI: 10.1109/ACCESS.2025.3584376

YAGIS, E. et al. (2021)
Effect of data leakage in brain MRI classification using 2D convolutional neural networks. *Scientific Reports*, 11, 22544.
DOI: 10.1038/s41598-021-01681-w

FATEH, A. et al. (2026)
BRISC: Annotated Dataset for Brain Tumor Segmentation and Classification. *Scientific Data*, 13, 361.
DOI: 10.1038/s41597-026-06753-y

Base, arquiteturas e explicabilidade

NICKPARVAR, M. (2021)
Brain Tumor MRI Dataset. Kaggle.
kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset

HE, K. et al. (2016)
Deep Residual Learning for Image Recognition. *CVPR*, p. 770–778.
DOI: 10.1109/CVPR.2016.90

TAN, M.; LE, Q. V. (2019)
EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *PMLR*, 97, p. 6105–6114.
proceedings.mlr.press/v97/tan19a.html

HOWARD, A. et al. (2019)
Searching for MobileNetV3. *ICCV*, p. 1314–1324.
DOI: 10.1109/ICCV.2019.00140

SELVARAJU, R. R. et al. (2017)
Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. *ICCV*, p. 618–626.
DOI: 10.1109/ICCV.2017.74