UNIVERSIDADE FEDERAL DE ALFENAS · UNIFAL-MG

Classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado

Uma análise comparativa de desempenho, eficiência computacional e explicabilidade

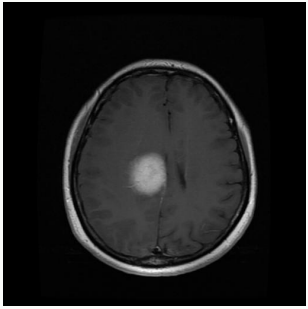
Pedro Brassi Luccas
Orientador: Prof. Dr. Luiz Eduardo da Silva

TCC I · Ciência da Computação · 2026



Exemplos da base Brain Tumor MRI Dataset (Nickparvar, 2021). Rótulos da base.

Contextualização



Exemplo da classe “meningioma”

1. A ressonância magnética permite visualizar detalhadamente estruturas cerebrais.
2. A interpretação dos exames exige conhecimento especializado.
3. A Inteligência Artificial pode auxiliar na identificação de padrões em imagens médicas.

Como a computação pode contribuir para a análise dessas imagens?

Imagem: Nickparvar (2021), Training/meningioma/Tr-me_10.jpg. Rótulo fornecido pela base, sem validação clínica independente.

Resultados na literatura

Estudos recentes relatam acurácias elevadas na classificação de tumores cerebrais por IA.

Disci et al. (2025)

98,73%

Uma rede pré-treinada (Xception)

Rasa et al. (2024)

99,96%

Testado em bases menores

Em bases maiores: 96,34% a 98,20%

Prayogo et al. (2025)

98,75%

Combinação de três redes pré-treinadas

Mas podemos confiar apenas nesses números?

Uma acurácia elevada não garante, isoladamente, uma boa capacidade de generalização.

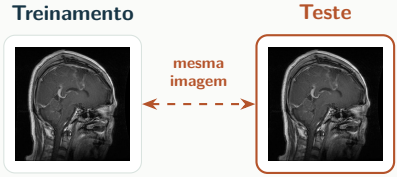
Cada estudo usou dados e métodos próprios, por isso os números não devem ser comparados entre si. Referências completas no slide 13.

Vazamento de dados: por que isso importa?

Yagis et al. (2021)

Até 55 p.p.

de inflação artificial da acurácia com divisão inadequada em fatias 2D.



Esquema conceitual com repetição intencional: o teste deixa de ser independente.

Fateh et al. (2026)

Removeram duplicatas exatas e quase duplicatas **antes da divisão**, em uma base derivada do mesmo conjunto público.

Lacuna investigada

Auditoria da base original combinada à comparação entre ResNet50, EfficientNet-B0 e MobileNetV3.

Yagis et al. (2021); Fateh et al. (2026). Imagem: Nickparvar (2021), Tr-gl_10.jpg. Lacuna conforme levantamento preliminar.

Justificativa

Por que investigar a confiabilidade, e não apenas a acurácia?

TEÓRICA

A metodologia precisa considerar a qualidade dos dados e o risco de vazamento, não só a acurácia final.

Diferencial: auditoria de duplicatas.

SOCIAL

O diagnóstico oportuno é importante no cuidado de tumores cerebrais.

Contribui para o apoio computacional ao diagnóstico por imagem, com potencial benefício indireto futuro.

TECNOLÓGICA

Bases públicas viabilizam o estudo sem coleta clínica direta.

Produz um pipeline reprodutível: auditoria, treinamento e explicabilidade.

Foco: a confiabilidade do método computacional, não uma ferramenta de uso clínico.

Pergunta e objetivos da pesquisa

PERGUNTA DE PESQUISA

Como a remoção de imagens duplicadas e a escolha da arquitetura influenciam o desempenho, o custo computacional e a interpretabilidade dos modelos?

OBJETIVO GERAL

Desenvolver e avaliar modelos de classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado, considerando desempenho, eficiência computacional, deduplicação e explicabilidade.

OBJETIVOS ESPECÍFICOS

01 Auditar a base
Identificar duplicatas exatas ou visualmente semelhantes.

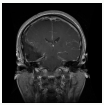
02 Treinar modelos
Uma CNN simples e três arquiteturas pré-treinadas.

03 Comparar
Desempenho, custo computacional e efeito da deduplicação.

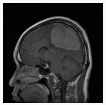
04 Investigar
Analisar os erros e as regiões destacadas pelo Grad-CAM.

Base de dados e preparação

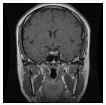
Brain Tumor MRI Dataset (Nickparvar, 2021), disponível no Kaggle: quatro categorias



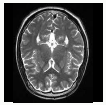
Glioma
origem: células da glia



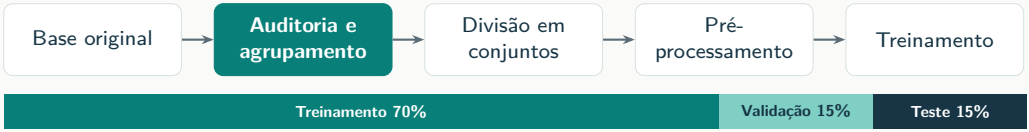
Meningioma
origem: meninges



Tumor hipofisário
origem: hipófise



Ausência de tumor
grupo de comparação



Auditoria: uma "impressão digital" (*hash*) de cada imagem revela cópias e quase cópias.

Duplicatas no mesmo conjunto ▪ Redimensionamento e normalização ▪ Aumento de dados somente no treino

Fonte: Nickparvar (2021). Rótulos da base. Sem identificadores para garantir separação por paciente.

Modelos e plano experimental

ARQUITETURAS PRÉ-TREINADAS

ResNet50
Rede profunda com conexões residuais

EfficientNet-B0
Equilíbrio entre desempenho e eficiência

MobileNetV3
Arquitetura compacta e eficiente

Transferência de aprendizado
Aproveitamento de características aprendidas previamente para adaptar os modelos à classificação de ressonâncias magnéticas.

PLANO EXPERIMENTAL

	Sem deduplicação	Com deduplicação
CNN simples (referência)	E1	E3
EfficientNet-B0	E2	E5
ResNet50	—	E4
MobileNetV3	—	E6

Efeito da deduplicação: E1 × E3 e E2 × E5
Comparação das arquiteturas: E4, E5 e E6

E7: análise de erros e explicabilidade com Grad-CAM no modelo selecionado.

Avaliação dos modelos e explicabilidade

Desempenho de classificação

Acurácia: proporção total de acertos

Matriz de confusão: quais classes são confundidas entre si

Macro F1: combina **precisão** (acertos entre os casos apontados para uma classe) e **sensibilidade** (casos de cada classe que o modelo encontra), com peso igual para as quatro classes

Eficiência computacional

Número de parâmetros
Tamanho do modelo (MB)
Tempo de inferência

Explicabilidade: Grad-CAM

Regiões que contribuíram para a pontuação do modelo. Análise exploratória do melhor modelo, em acertos e erros.

Avaliar quanto o modelo acerta, quanto custa e quais regiões influenciam suas decisões.

Selvaraju et al. (2017). Grad-CAM não é segmentação nem comprovação de correção clínica.

Hipóteses e limitações

Hipóteses (a testar)

H1 · Deduplicação
A remoção de duplicatas reduzirá métricas artificialmente elevadas.

H2 · Desempenho × custo
EfficientNet-B0 tende ao melhor equilíbrio; MobileNetV3, ao menor custo.

H4 · Explicabilidade
O Grad-CAM ajudará a revelar decisões baseadas em regiões irrelevantes.

Limitações

Identificação dos pacientes
A base não disponibiliza identificadores para garantir separação por paciente.

Generalização
Resultados em uma base pública não garantem desempenho em outros contextos.

Aplicação clínica
O projeto não pretende validar uma ferramenta de diagnóstico médico.

Contribuição esperada: uma avaliação mais criteriosa da classificação de tumores cerebrais por IA. As hipóteses serão confirmadas ou rejeitadas pelos experimentos.

Cronograma da pesquisa

Planejamento indicativo de seis meses, a ajustar com o orientador

Atividade	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6
Tema e problema	C					
Revisão bibliográfica	P					
Base e documentação	C					
Auditoria/deduplicação						
Pré-processamento						
Baseline						
Treinamento (E1–E6)						
Ajustes						
Avaliação						
Grad-CAM (E7)						
Extensões (se houver tempo)						
Redação	P					
Revisão/apresentação						

C concluído P parcialmente realizado vazio: período a definir

Fonte: pré-projeto, p. 8

Mais do que obter uma alta acurácia, é necessário avaliar a confiabilidade dos resultados.

- Qualidade dos dados
- Avaliação comparativa
- Explicabilidade

Obrigado! Perguntas?

Referências bibliográficas

Classificação e qualidade dos dados

DISCI, R.; GURCAN, F.; SOYLU, A. (2025)
Advanced brain tumor classification in MR images using transfer learning and pre-trained deep CNN models. *Cancers*, 17, 121.
DOI: 10.3390/cancers17010121

RASA, S. M. et al. (2024)
Brain tumor classification using fine-tuned transfer learning models on magnetic resonance imaging (MRI) images. *Digital Health*, 10.
DOI: 10.1177/20552076241286140

PRAYOGO, R. D.; HAMID, N.; NAMBO, H. (2025)
Hybrid CNN-Based Transfer Learning Enhances Brain Tumor Classification on MRI Images. *IEEE Access*, 13, 116654–116668.
DOI: 10.1109/ACCESS.2025.3584376

YAGIS, E. et al. (2021)
Effect of data leakage in brain MRI classification using 2D convolutional neural networks. *Scientific Reports*, 11, 22544.
DOI: 10.1038/s41598-021-01681-w

FATEH, A. et al. (2026)
BRISC: Annotated Dataset for Brain Tumor Segmentation and Classification. *Scientific Data*, 13, 361.
DOI: 10.1038/s41597-026-06753-y

Base, arquiteturas e explicabilidade

NICKPARVAR, M. (2021)
Brain Tumor MRI Dataset. Kaggle.
kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset

HE, K. et al. (2016)
Deep Residual Learning for Image Recognition. *CVPR*, p. 770–778.
DOI: 10.1109/CVPR.2016.90

TAN, M.; LE, Q. V. (2019)
EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *PMLR*, 97, p. 6105–6114.
proceedings.mlr.press/v97/tan19a.html

HOWARD, A. et al. (2019)
Searching for MobileNetV3. *ICCV*, p. 1314–1324.
DOI: 10.1109/ICCV.2019.00140

SELVARAJU, R. R. et al. (2017)
Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization. *ICCV*, p. 618–626.
DOI: 10.1109/ICCV.2017.74